

Neural Denoising for Path Tracing of Medical Volumetric Data

Dezeming Family

2023年7月18日

DezemingFamily系列文章和电子书**全部都有免费公开的电子版**，可以很方便地进行修改和重新发布。如果您获得了DezemingFamily的系列电子书，可以从我们的网站[<https://dezeming.top/>]找到最新的版本。对文章的内容建议和出现的错误也欢迎在网站留言。

目录

一 介绍	1
二 相关工作	1
三 网络的结构	1
3 1 输入的辅助特征	1
3 2 损失函数	1
3 3 网络结构	2
3 4 时序特征	2
参考文献	2

一 介绍

进行了时空去噪，引入样本重投影，并且专门为体渲染的去噪设计了额外的特征和损失函数。

- 我们定义了许多适用于体情况的噪声辅助特征，并通过定义一种新的双自动编码器网络架构来实现对这些特征的合理解释，分别处理直接照明计算所需的特征和间接照明计算所需要的特征。
- 此外，我们提出了一种新的损失函数，专门用于镜面高光的清晰重建。
- 我们在双自动编码器网络中添加了一个相对鉴别器(relativistic discriminator)（如生成对抗性网络中使用的）。
- 本文的最后一个贡献是通过特征重投影阶段扩展我们的网络架构，以增强时间稳定性。

二 相关工作

一些比较有趣的相关工作：

While previous approaches require ground-truth renderings for training a denoising network, it can be shown that convergence is also achievable from training on two [Lehtinen et al. 2018] or a single [Krull et al. 2019] noisy rendering, given certain constraints regarding the loss function and noise distribution. Instead of gathering summaries over the pixel neighborhood, learning how to splat sample contributions onto neighboring pixels can further increase reconstruction fidelity [Gharbi et al. 2019]. Adaptations of learning-based denoising to gradient-domain rendering, where more frequency content is available for filtering, have been proposed as well [Guo et al. 2019; Kettunen et al. 2019]

三 网络的结构

3.1 输入的辅助特征

primary auxiliary包含有第一次散射事件的位置、梯度、albedo以及三通道信息的体特征图（梯度模、光学厚度和第一次散射事件发生时的衰减系数）。secondary auxiliary features记录第一次表面散射事件（可以是第一次、第二次或任何其他散射事件）后的颜色、第二个散射事件位置的反照率，以及类似于primary auxiliary的体特征图。这些secondary特征包括更高的噪声量，因此需要设计专门的网络架构，以从这些特征中最佳地获得信息。



Fig. 3. Feature vector for two exemplary images from our training set. From left to right: (a) target image; (b) noisy image with one sample per pixel; (c) primary auxiliary features: model space position, world space normal and albedo of the first scatter event, volumetric characteristics up to the first scatter event; (d) secondary auxiliary features: color after first surface scatter event, albedo of the second scatter event, volumetric characteristics from the first to the second scatter event.

3.2 损失函数

我们重建的损失函数包括 L_1 损失与高光损失。 L_1 损失包括颜色损失和颜色梯度损失（梯度用高斯模糊计算，防止噪声干扰(High Frequency Error Norm)），之所以用 L_1 是因为[Zhao et al. 2016]中描述使用 L_2 会导致可见的artifacts。

高光损失其实就是：减去局部邻域的平均值并抑制负值，高光被隔离并选择性地与reference进行比较，见论文公式(2)。

3 3 网络结构

使用具有跳跃连接的U-Net布局 [Ronneberger et al. 2015]和有利于解码器部分的不对称权重计数[Lehtinen et al. 2018]。

3 4 时序特征

时序特征用重投影的方法得到，论文中说，由于相机的移动是平滑的，因此重投影方法比较合理。

增加时间稳定性的一种可能性在于简单地增加单个输出图像的质量，因为每个单独帧的较小误差导致帧之间的闪烁减少。因此，如论文第8节的比较分析所述，第3、4、5和6节中描述的每一项改进都有助于实现时间稳定性的目标。合并来自先前或后续帧的样本提供了进一步增强时间稳定性的选项。通过将时域包括在滤波过程中，我们增加了对每个像素有贡献的样本数量，从而在没有额外渲染成本的情况下提高了单个帧的时间稳定性和整体图像质量。

为了能够包括来自时序相邻帧的样本，尽管相机在其间移动，我们以类似于Karis[Caris 2014]的方式重新投影样本（颜色和特征），将它们带到同一空间。作为重投影所需的深度值，我们选择到第一个散射事件的距离，即使对于静态相机设置，由于不确定的散射，在体情况下，它也会受到随机抖动。相机的移动以及随时间变化的传递函数进一步加剧了问题。由于重投影在很大程度上取决于深度，因此来自相邻帧的重投影特征图表现出比同一帧的特征中已经存在的噪声量更高的噪声量，以及比在表面的重投影中发现的更高的遮挡/不遮挡量。因此，我们将考虑的帧数限制为前一帧和后一帧，每个像素总共考虑三个样本。在这个时间窗口中，由于在我们的用例（医学数据集的检查）中相机移动相对缓慢和平滑，重投影可以被认为是有意义的。

参考文献

- [1] Hofmann N, Martschinke J, Engel K, et al. Neural denoising for path tracing of medical volumetric data[J]. Proceedings of the ACM on Computer Graphics and Interactive Techniques, 2020, 3(2): 1-18.